RAG 学习资料

第一部分：什么是 RAG

RAG 的中文名称是检索增强生成。它让大语言模型在回答问题之前，先从外部知识库中查找相关资料，再根据检索结果组织答案。

RAG 的目标不是重新训练模型，而是在调用模型时为它补充当前问题需要的背景资料。知识库可以来自文本文件、Markdown、PDF、数据库或者企业内部文档。

> 核心流程：用户问题 → Embedding → 向量检索 → 相关文本块 → 大模型生成回答。

第二部分：主要组成

文档加载器负责把不同格式的文件转换成 Document；文本切分器把长文档切成较小的 chunk；Embedding 模型把文字转换成向量；向量数据库负责保存和检索向量；聊天模型根据资料回答问题。

RAG 实践要点

一、保留来源信息

每个 Document 都应该保留 source、title、page 等 metadata。这样最终回答可以展示资料来源，用户也能回到原文核对答案。PDF 通常是一页对应一个 Document。

二、控制文本块大小

文本块太大可能包含过多无关内容，文本块太小则可能破坏完整语义。chunk_overlap 可以在相邻文本块之间保留少量重叠内容。

三、避免重复建立索引

可以使用文件指纹判断文档是否发生变化。未变化文件跳过加载、切分和 Embedding；新增文件建立新索引；修改文件替换旧索引；删除文件清理对应的文本块。

> 测试问题建议：什么是 RAG？RAG 包含哪些主要组件？为什么要保留 metadata？